

**МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра МОЭВМ**

ОТЧЕТ

**по лабораторной работе №1
по дисциплине «Интеллектуальные методы анализа данных»
Тема: Первичный анализ и предобработка природного временного ряда**

Студент гр. 3381
Преподаватель

Кулаков А.Ю.
Мандрикова Б.С.

Санкт-Петербург
2026

Цель работы.

Повышение качества природных данных на примере наблюдений нейтронных мониторов.

Задание.

1. Скачать данные из источника <https://www.nmdb.eu/nest/> за периоды и станции, указанные по вариантам. Использовать данные с одноминутным временным разрешением.
2. Выполнить обнаружение пропусков и выбросов (3σ) в анализируемом временном ряде, посчитать их количество и долю от всех обрабатываемых данных.
3. С помощью функции `median` вычислить медианное значение по данным без пропусков и выбросов.
4. Заменить пропуски и выбросы медианными значениями.
5. Изобразить графики исходного и полученного временных рядов.
6. Сделать соответствующие выводы, оформить отчет по работе.

Выполнение работы.

Работа выполнялась на языке Python. Для обработки данных использовалась библиотека `pandas`, для построения графиков — `seaborn` и `matplotlib`. Исходный код программы приведен в приложении А.

Данные считываются из файла `'./lb1/data.csv'` с разделителем `'.'`. Для проверки результата загрузки в программе выводятся первые пять строк:

	start_date_time	RCORR_E
0	2014-11-01 00:00:00	236.34
1	2014-11-01 00:01:00	236.34
2	2014-11-01 00:02:00	237.82
3	2014-11-01 00:03:00	232.96
4	2014-11-01 00:04:00	234.17

После преобразования столбца `start_date_time` в формат даты и времени выводятся размер таблицы и результат функции `describe()`:

```
(12960, 2)
      start_date_time  RCORR_E
count              12960  12960.000000
mean  2014-11-05 11:59:30   234.220844
min    2014-11-01 00:00:00    0.000000
25%    2014-11-03 05:59:45   231.040000
50%    2014-11-05 11:59:30   233.560000
75%    2014-11-07 17:59:15   236.140000
max    2014-11-09 23:59:00  9164.470000
std                                NaN    78.595767
```

Размер таблицы равен (12960, 2). Значение `count` для `RCORR_E` в результате `describe()` также равно 12960. Следовательно, пропущенных значений в столбце `RCORR_E` нет.

В результате `describe()` для `RCORR_E` получены среднее значение 234.220844 и стандартное отклонение 78.595767.

Выбросы определяются в программе условием $\text{abs}(\text{df}[\text{'RCORR_E'}] - \text{mean}) > 3 * \text{std}$.

Результат подсчета записей, удовлетворяющих этой маске:

```
start_date_time    1
RCORR_E            1
dtype: int64
```

Таким образом, программой обнаружен 1 выброс.

Доля от всех данных рассчитывается в коде выражением $d = 1 / 12960$. Полученное значение, выведенное программой:

```
0.000077
```

После исключения выброса формируется `df_no_anomaly`, затем методом `median()` вычисляется медианное значение `RCORR_E`. Результат:

```
233.56
```

После этого для записей, соответствующих маске выбросов, значение `RCORR_E` заменяется на вычисленную медиану командой `df.loc[mask, 'RCORR_E'] = med`. Поскольку пропущенных значений в `RCORR_E` не обнаружено, замена выполняется только для найденного выброса.




Рисунок 1 — График исходных данных.




Рисунок 2 — График данных после замены выброса медианным значением.

Выводы.

В ходе работы данные были загружены и проанализированы. По результатам `shape` и `describe()` пропущенные значения в столбце `RCORR_E` отсутствуют. По критерию 3σ обнаружен 1 выброс. Выведенная программой доля от всех данных равна 0.000077. Медианное значение данных после исключения выброса равно 233.56. Найденный выброс заменен медианным значением, после чего построен график обработанного временного ряда.

ПРИЛОЖЕНИЕ А

ИСХОДНЫЙ КОД ПРОГРАММЫ

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

df = pd.read_csv('./lb1/data.csv', sep=';')
print(df.head())
df['start_date_time'] = pd.to_datetime(df['start_date_time'])
print(df.shape)
print(df.describe())
std = df['RCORR_E'].std()
mean = df['RCORR_E'].mean()
mask = (abs(df['RCORR_E'] - mean) > 3 * std)
print((df[mask]).count())
lower = mean - 3 * std
upper = mean + 3 * std
sns.lineplot(data=df, x='start_date_time', y='RCORR_E')
plt.axhline(upper, color='red', linestyle='--')
plt.axhline(lower, color='red', linestyle='--')
plt.ylim(-3, 800)
plt.show()

d = 1 / 12960
print(f"{d:.6f}") # доля от всех данных
df_no_anomaly = df[~mask]
med = df_no_anomaly['RCORR_E'].median()
print(med)
df.loc[mask, 'RCORR_E'] = med
sns.lineplot(data=df, x='start_date_time', y='RCORR_E')
plt.show()
```